

# Previsione dell'abbandono clienti (Customer Churn)

Progetto del corso Introduzione al Pensiero Computazionale e alla Data Science

Alessia

Michelle

25 agosto 2026

## Sommario

Questo report presenta un'analisi del dataset *Customer Churn*, relativo a clienti di un'azienda di telecomunicazioni, con l'obiettivo di individuare i fattori associati all'abbandono del servizio e di costruire modelli predittivi in grado di identificare i clienti a rischio. Vengono confrontati tre modelli di classificazione (Regressione Logistica, k-Nearest Neighbors, Random Forest) e discussi i risultati alla luce dello squilibrio tra le classi e dell'interpretabilità di ciascun approccio. Il codice sorgente e i notebook completi sono disponibili nel repository GitHub del progetto: <https://github.com/ale19ssia/progetto-data-science>.

## 1 Introduzione

L'abbandono dei clienti (*churn*) è uno dei problemi più comuni affrontati dalle aziende che operano con un modello di business ad abbonamento, come le compagnie di telecomunicazioni. Prevedere in anticipo quali clienti sono a rischio di abbandono permette di intervenire con azioni mirate di fidelizzazione, riducendo i costi legati all'acquisizione di nuovi clienti.

L'obiettivo di questo progetto è duplice: da un lato comprendere quali caratteristiche dei clienti sono più associate all'abbandono attraverso un'analisi esplorativa dei dati; dall'altro costruire e confrontare diversi modelli di classificazione in grado di prevedere la variabile target **Churn** (Sì/No).

Il lavoro è organizzato in sei fasi, seguendo la struttura richiesta dal corso: comprensione del dataset, analisi esplorativa, modellazione, valutazione dei risultati e, infine, questo report. Tutto il codice, i notebook eseguiti e la cronologia dello sviluppo sono disponibili nel repository GitHub del progetto.

## 2 Il dataset

Il dataset utilizzato (**Customer\_Churn.csv**) contiene informazioni su 7043 clienti di un'azienda di telecomunicazioni, descritti da 21 variabili suddivise in quattro categorie: dati demografici (genere, se cliente anziano, presenza di partner o persone a carico), servizi sottoscritti (telefono, internet, sicurezza online, supporto tecnico, streaming, ecc.), informazioni contrattuali (durata del rapporto in mesi, tipo di contratto, metodo di pagamento, addebiti mensili e totali) e la variabile target **Churn**.

La variabile target è moderatamente sbilanciata: il 73.5% dei clienti è rimasto attivo, mentre il 26.5% ha abbandonato il servizio. Questo squilibrio ha guidato alcune scelte metodologiche descritte nella Sezione 3.

Durante la fase di comprensione dei dati è emerso un problema di qualità non evidente a un primo controllo: la colonna **TotalCharges**, pur rappresentando un importo, era codificata come testo. Analizzando le righe non convertibili in valore numerico, sono stati individuati 11 clienti con un valore vuoto, tutti caratterizzati da **tenure** = 0, cioè clienti appena iscritti e non ancora

fatturati. Non si tratta quindi di un errore casuale, ma di un caso sistematico e spiegabile: questi valori sono stati impostati a zero prima della modellazione.

È stato inoltre verificato che `customerID` è un identificativo univoco per ogni cliente, privo di valore predittivo, ed è stato escluso dalle variabili utilizzate nei modelli.

## 3 Metodologia

### 3.1 Preparazione dei dati

Prima della modellazione, i dati sono stati trasformati come segue: rimozione della colonna identificativa `customerID`; codifica binaria (0/1) delle variabili con due sole categorie (es. `Partner`, `Dependents`, `PaperlessBilling`); codifica *one-hot* delle variabili con più di due categorie (es. `Contract`, `PaymentMethod`, `InternetService`). Il dataset è stato quindi suddiviso in un training set (75%) e un test set (25%), mantenendo la stessa proporzione di clienti che abbandonano in entrambi gli insiemi (*stratified split*). Le variabili numeriche sono state standardizzate (media 0, deviazione standard 1) per i modelli basati sulla distanza o su un'ottimizzazione lineare (Regressione Logistica, k-NN); la standardizzazione non è stata applicata per la Random Forest, che non ne necessita.

### 3.2 Modelli utilizzati

Sono stati addestrati e confrontati tre modelli di classificazione, come richiesto dalle specifiche del progetto:

- **Regressione Logistica** (modello lineare): stima la probabilità che un cliente abbandoni come

$$P(\text{Churn} = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (1)$$

dove  $x_1, \dots, x_n$  sono le variabili standardizzate e  $\beta_1, \dots, \beta_n$  i coefficienti stimati dal modello.

- **k-Nearest Neighbors** ( $k = 5$ , modello non lineare): classifica un cliente in base alla classe maggioritaria tra i 5 clienti più simili nel training set, secondo la distanza euclidea.
- **Random Forest** (200 alberi, modello non lineare): combina le previsioni di molti alberi decisionali addestrati su sottoinsiemi diversi di dati e variabili.

Data la moderata sbilanciatura delle classi, per Regressione Logistica e Random Forest è stato utilizzato il parametro `class_weight="balanced"`, che assegna un peso maggiore agli esempi della classe minoritaria durante l'addestramento. Il k-NN non dispone nativamente di questo meccanismo.

### 3.3 Metriche di valutazione

Per ciascun modello sono state calcolate: accuratezza (*accuracy*), precisione (*precision*), richiamo (*recall*) e F1-score sulla classe di interesse (`Churn = Sì`), oltre alla matrice di confusione. La F1-score è definita come la media armonica tra precisione e richiamo:

$$F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (2)$$

Dato lo squilibrio delle classi, l'accuratezza da sola non è una metrica sufficiente: un modello che prevedesse sempre “non abbandona” otterrebbe già un'accuratezza del 73.5% senza fornire alcuna utilità pratica. Per questo motivo è stata data particolare attenzione alla recall sulla classe `Churn`, che misura la capacità del modello di individuare i clienti realmente a rischio.

## 4 Risultati

### 4.1 Analisi esplorativa

L'analisi esplorativa ha permesso di verificare diverse ipotesi formulate durante la fase di comprensione del dataset. Il fattore più fortemente associato all'abbandono è risultato il tipo di contratto (Figura 1): i clienti con contratto mensile abbandonano nel 42.7% dei casi, contro l'11.3% dei contratti annuali e il 2.8% dei contratti biennali. Anche l'anzianità del cliente (**tenure**) mostra una relazione marcata con l'abbandono: i clienti che abbandonano hanno una permanenza mediana di 10 mesi, contro i 38 mesi circa di chi resta cliente.




Figura 1: Tasso di abbandono (%) per tipo di contratto.

È stata inoltre verificata la presenza di collinearità tra le variabili numeriche del dataset (Figura 2): **TotalCharges** risulta fortemente correlata sia con **tenure** (0.83) sia con **MonthlyCharges** (0.65), un aspetto tenuto in considerazione nell'interpretazione dei coefficienti della Regressione Logistica.

Un'ulteriore ipotesi verificata riguarda il tipo di connessione internet (Figura 3): i clienti con fibra ottica abbandonano nel 41.9% dei casi, contro il 19.0% dei clienti con connessione DSL e il 7.4% di chi non ha internet. La connessione in fibra ottica mostra quindi una forte associazione con il churn, seconda per entità solo al tipo di contratto tra le variabili categoriche esaminate in questa sezione, coerentemente con il coefficiente più positivo osservato nella Regressione Logistica (Sezione 4.3).

Infine, anche il metodo di pagamento mostra un'associazione con l'abbandono (Figura 4): i clienti che pagano tramite **Electronic check** abbandonano nel 45.3% dei casi, contro percentuali inferiori al 20% per gli altri tre metodi disponibili. Una possibile spiegazione è che questo metodo di pagamento sia più diffuso tra clienti con caratteristiche già associate al churn, come il contratto mensile; verificare questa ipotesi richiederebbe però un'analisi congiunta delle due variabili, che esula dagli obiettivi di questo report.

### 4.2 Confronto tra i modelli

La Tabella 1 riporta le metriche di valutazione calcolate sul test set per i tre modelli.




Figura 2: Matrice di correlazione tra le variabili numeriche.




Figura 3: Tasso di abbandono (%) per tipo di connessione internet.

Tabella 1: Confronto delle prestazioni dei tre modelli sul test set (classe **Churn**).

| Modello               | Accuracy     | Precision    | Recall       | F1-score     |
|-----------------------|--------------|--------------|--------------|--------------|
| Regressione Logistica | 0.750        | 0.519        | <b>0.797</b> | <b>0.628</b> |
| k-Nearest Neighbors   | 0.752        | 0.534        | 0.516        | 0.525        |
| Random Forest         | <b>0.792</b> | <b>0.644</b> | 0.484        | 0.553        |




Figura 4: Tasso di abbandono (%) per metodo di pagamento.

La Random Forest raggiunge l'accuratezza e la precisione più alte, ma è la Regressione Logistica a ottenere la recall più elevata (0.797): individua quindi la quota maggiore di clienti che abbandonano realmente, a fronte di un numero maggiore di falsi positivi. Il k-NN ottiene le prestazioni più basse tra i tre modelli; la recall inferiore può essere in parte legata all'assenza di un meccanismo nativo di bilanciamento delle classi, oltre che alla sensibilità del k-NN alla struttura locale dei dati e alla scelta di  $k$ .




Figura 5: Confronto grafico delle metriche di valutazione tra i tre modelli.

Le matrici di confusione dei tre modelli (Figura 6) mostrano nel dettaglio la distribuzione degli errori: si nota chiaramente come la Regressione Logistica commetta meno falsi negativi (clienti a rischio non individuati) rispetto agli altri due modelli, a fronte di un numero maggiore di falsi positivi.

### 4.3 Fattori più rilevanti

La Figura 7 mostra le dieci variabili con maggiore *feature importance* secondo la Random Forest. Le tre variabili più rilevanti sono **TotalCharges** (0.176), **tenure** (0.169) e **MonthlyCharges** (0.150), coerentemente con la collinearità tra queste variabili già osservata in Sezione 3. Va però precisato che, in presenza di variabili fortemente correlate come queste, l'importanza calcolata dalla Random Forest può ripartirsi tra le variabili che condividono informazione simile: il fatto




Figura 6: Matrici di confusione a confronto per i tre modelli sul test set.

che **TotalCharges** compaia al primo posto non implica quindi, in senso assoluto o causale, che sia la determinante più forte del churn. Il tipo di contratto, pur comparendo più in basso in questa classifica, resta rilevante: avere un contratto biennale (**Contract\_Two year**) è la quarta feature per importanza ed è anche uno dei coefficienti più negativi – quindi più protettivi – nella Regressione Logistica. Il coefficiente positivo più forte nella Regressione Logistica è invece **InternetService\_Fiber optic** (+0.78), coerente con quanto osservato nell’analisi esplorativa (Sezione 4.1): i clienti con fibra ottica abbandonano molto più spesso. Il fatto che due modelli molto diversi tra loro (uno lineare, uno basato su alberi) concordino sui fattori principali rafforza la robustezza descrittiva del risultato, pur trattandosi in entrambi i casi di associazioni statistiche e non di relazioni causali dimostrate.




Figura 7: Le 10 variabili più rilevanti secondo la Random Forest.

## 5 Discussione

I risultati ottenuti evidenziano un compromesso tipico nei problemi di classificazione con classi sbilanciate: la Random Forest privilegia la precisione, mentre la Regressione Logistica, grazie al bilanciamento delle classi, privilegia la recall. Nel contesto applicativo di questo progetto – identificare clienti a rischio di abbandono per interventi di fidelizzazione – un falso negativo (un cliente a rischio non individuato) è generalmente più costoso di un falso positivo (un cliente

stabile contattato per errore). Su questa base, la Regressione Logistica risulta il modello più adatto tra i tre, nonostante l'accuratezza più bassa.

Dal punto di vista dell'interpretabilità, la Regressione Logistica è anche il modello più trasparente: i suoi coefficienti indicano direttamente la direzione e l'intensità dell'associazione stimata tra ciascuna variabile e la probabilità di churn. La Random Forest offre comunque una misura di interpretabilità tramite la feature importance, mentre il k-NN non fornisce alcuna indicazione diretta sull'importanza delle variabili.

Un limite comune a tutti i modelli è la precisione relativamente contenuta sulla classe **Churn** (tra il 52% e il 64%): un'azienda che utilizzasse questi modelli per decidere quali clienti contattare dovrebbe considerare che una parte non trascurabile dei clienti segnalati come a rischio in realtà non abbandonerebbe. Va inoltre ricordato che la feature importance e i coefficienti stimati indicano associazioni statistiche apprese dal modello, non necessariamente relazioni di causa-effetto.

Dal punto di vista computazionale, la Random Forest (200 alberi) è il modello più oneroso da addestrare, sebbene su un dataset di questa dimensione la differenza rispetto agli altri due modelli sia contenuta a pochi secondi.

## 6 Conclusioni

L'analisi condotta ha permesso di identificare i fattori più associati all'abbandono dei clienti in un'azienda di telecomunicazioni: il tipo di contratto, l'anzianità del cliente e, in misura minore, il metodo di pagamento e l'addebito mensile. Tra i tre modelli di classificazione confrontati, la Regressione Logistica rappresenta il miglior compromesso tra capacità predittiva (in particolare la recall sulla classe di interesse) e interpretabilità dei risultati, mentre la Random Forest offre l'accuratezza complessiva più alta.

Come sviluppi futuri, sarebbe utile esplorare tecniche di bilanciamento delle classi più sofisticate (ad esempio SMOTE), l'ottimizzazione degli iperparametri dei modelli tramite ricerca sistematica (*grid search*), e l'introduzione di nuove variabili derivate (ad esempio il rapporto tra **TotalCharges** e **tenure**) per catturare meglio il comportamento dei clienti nel tempo.

## Nota sull'uso di strumenti di intelligenza artificiale

Il progetto è stato realizzato con il supporto di un assistente basato su un modello linguistico (Claude), utilizzato come aiuto alla programmazione e alla spiegazione dei concetti statistici e di machine learning applicati. Tutte le ipotesi, le scelte metodologiche e le interpretazioni dei risultati presentate in questo report sono state discusse e comprese dagli autori. Maggiori dettagli sono disponibili nel README del repository.

## Riferimenti bibliografici

- [1] IBM Sample Data Sets, *Telco Customer Churn*. Dataset fornito nell'ambito del corso Introduzione al Pensiero Computazionale e alla Data Science, Università di Bologna, A.A. 2025/2026.
- [2] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [3] Waskom, M. L. (2021). *seaborn: statistical data visualization*. Journal of Open Source Software, 6(60), 3021.
- [4] Poggi, F. (2026). *Slide del corso Introduzione al Pensiero Computazionale e alla Data Science*. Dipartimento di Scienze Politiche e Sociali, Università di Bologna.